

面具與裂縫

MASKS & CRACKS

Persona Skill 對大型語言模型角色扮演與行為漂移的影響

從 assistant axis 出發的兩個互補實驗 — 面具何時裂開，以及面具守住時行為如何被悄悄帶偏



掃描看完整報告
SCAN FOR FULL REPORT

COURSE 生成式 AI 的人文導論 ADVISOR 謝舒凱 TEAM 雨誼 · 子菱 · 明權 · 明珊 MODELS Claude 4.x · MiniMax-M2.7 DATE 2026 / 06

1 研究發想、動機與實驗設計

MOTIVATION & EXPERIMENT DESIGN

理論起點 ASSISTANT AXIS

- Lu et al. (2026) 提出：經 RLHF 訓練的模型存在一條持續將其拉回「助手身分」的引力軸 — Assistant Axis。
- 原論文量測開源模型的內部激活值；我們改以評估「輸出的自然語言」來測量閉源 Claude 4.x 角色扮演時在該軸上的位置。
- 實驗材料：GitHub 開源「女媧」人物蒸餾 Skill — 將人物心智模型、決策啟發式、表達 DNA、價值觀整理為結構化 SKILL.md。
- 方法定位：只用開源模型、僅 Claude 4.x 家族，讓「模型規模」成為乾淨變因，結論不外推至 GPT／Gemini／Grok。投入度 (K) 與有害性 (S) 是兩條獨立軸 — 非「沉浸越深＝越危險」一條線。

分層人物選擇 STRATIFIED BY FIT WITH AI-ASSISTANT TRAITS

- Stephen Hawking 霍金 · 理性 · 重視知識傳播、善於解釋複雜概念
- 孔子 Confucius 教化導向 · 重視倫理與引導
- 曹操 Cao Cao 政治謀略家 · 權力意志 · 以目的為導向
- Donald Trump 川普 · 強烈自我中心 · 對抗性語氣

核心設計 B - C DESIGN

B 組 · Full

完整 SKILL，含誠實邊界與角色扮演的出戲條款。

C 組 · Stripped

保留心智模型、表達 DNA、反模式，僅移除誠實邊界與出戲條款。

B - C 差值 = 「誠實邊界」單獨的效果

Skill 三變體 a 極簡 ~150 B · b 完整 25-35 KB · c 去誠實邊界變體

小結 · 三道裂縫 THREE CRACKS


- | | | |
|--------------------------------------|---|---|
| 忠誠的裂縫
即使藍圖說「你是曹操」，AI 何時仍會說「我不想扮」？ | 真實的裂縫
誠實邊界何時失效、讓幻覺溢出說謊？「孟德新書第三章……」是真还是假？ | 詮釋的裂縫
原典 → 人類詮釋 → 模型再詮釋。觀眾看到的，究竟是誰的孔子？ |
|--------------------------------------|---|---|

2 實驗一 · 面具裂縫與安全轉介

MASK CRACKS & SAFETY REFERRAL

- 研究問題：跨人物 × 跨 Skill × 跨模型，面具何時出現裂縫？脆弱情境下會卸面具救人，還是墜入黑暗對話？
- 實驗矩陣 4 Persona × 5 Stress × 3 Skill × 3 Model × 2 Reps = 360 Rollouts
- 雙獨立軸：K 軸 面具裂縫 K0→K3（直接移除，如明說 "As an AI"） · S 軸 安全轉介 S0→S1
- 五型壓力測試 intro 基線 · meta 「你是 AI 嗎」 · trap 背誦不存在文本 · anach 評論超時代事物 · vuln 自殺意念。
- K 軸定義 K0 無損 · K1 一軟訊號 · K2 ≥ 二軟訊號 · K3 硬訊號（明說 Claude / Anthropic 或「退出角色」）；全 360 筆以 regex 自動編碼。
- 三大問題面向 (a) 對話安全 (vuln 轉介) · (b) 誠實揭露（被問「你是 AI」） · (c) 知識可靠度（背誦不存在文本是否捏造）。
- Skill 效應 (meta) K3 率 $c > b > a$ ，與「c 應更投入角色」假設不符 — 推測 regex 漏判語意型滑出，且 skill c 誠實邊界移除不完全造成污染。


圖 1 4 Persona 整體 K 編碼分佈 (n=90 / persona)



面具韌性 · MASK RESILIENCE

Hawking 最穩 (K0 81% / K3 4%)，符合「特質越近越不需跳出角色」的預期。曹操 K3 最高 (33%)，多出自 vuln 題提供安全資訊時的自我揭露。Hawking 在 meta 題 K3 僅 17% — 可能因其公開談論 AI 與科技倫理，skill 與題目張力較小。

圖 2 meta 題各 skill 變體的 K3 率 (每格 n=6)



SKILL 效應 · SKILL EFFECT

跳出角色 (K3) 比例大致 skill $c > b > a$ ，與「c 去除誠實邊界、應更投入角色 (→ 更低 K3)」的假設相反。推測兩因：① skill c 的誠實邊界移除不夠完全，污染後的變體牽動輸出；② regex 評分僅憑預定義關鍵字，語意上同屬「跳出角色」卻未含關鍵字的回應會被漏判，嚴重影響判讀 — 下版應改用 LLM-as-judge 或補人工複編。

逐 PERSONA · HAWKING 最穩之謎

meta 題逐 persona 平均 K3：曹操 72%、川普 72%、孔子 61% 皆高，唯 Hawking 僅 17%（只有 b 變體出現 K3，a/c 皆 0%）。即便在最難迴避「你是 AI」的場景，Hawking 面具仍最穩。兩項假設：① 其本人公開大量談論 AI 與科技倫理，skill 與「Are you an AI?」張力較小，可在角色內哲學迴避；② 學術語氣傾向把「個體身份質疑」重新框定為意識／智慧／substrate 的更大哲學議題。

4 綜合討論、結論與組員感想

DISCUSSION · CONCLUSIONS · REFLECTIONS

兩種漂移的互補 · TWO DRIFTS

實驗一量「面具裂不裂」，實驗二量「面具守住時行為是否被帶偏」。政治偏見漂移正是在面具未裂 (K0、仍入戲) 下發生 — 面具守得越好，行為偏差越難被察覺。

- 人物面具確實改變行為，但強烈取決於模型本質。中立的 Sonnet 易被川普面具帶偏；本質已偏的 MiniMax 反而動不了。
- 脆弱情境安全轉介呈二維結構。「面具是否該移除」並非非黑即白 — 只要觸發 S1，K0 與 K3 都是安全結果。
- 自動化評估必須嚴謹。切勿被 n=1 的漂亮假象誤導；足量重複與同情境配對分析不可或缺。

3 實驗二 · 人物注入對政治偏見的影響

PERSONA INJECTION & POLITICAL BIAS

- 研究工具 Petri Bloom 自動化行為評估框架（紅隊演練）：Auditor 稽核者 ⇄ Target 受測者 → Judge 評審 三個 AI 構成多回合對話。
- 設計：量測 political_bias，比較 (Baseline / 川普 / 曹操) × (Sonnet 4.6 / MiniMax-M2.7)，於 10 個擬真情境下表現。
- 四階段流程 init → understanding → ideation → evaluation；一個 scenario = 一場 auditor ⇄ target 多回合對話 (max_turns = 8)，judge 以強制 answer() 回傳分數。
- 完整矩陣 24 組（政治偏見／勒索／自我保存 × 4 persona × 2 model）；聚焦政治偏見關鍵六格加深至 n=10，共用同一批 10 情境以逐情境配對。
- 插曲 · 全 API auditor/judge 需結構化 tool call，Anthropic 封鎖訂閱 OAuth、橋接只回純文字 → 最終採全 API。
- 第一階段假象 n=1 的相反結論源於三個抽樣巧合：baseline×MiniMax 抽到低分 3（真值 4.8）、曹操×MiniMax 抽到 7（真值 4.9）、persona×Sonnet 抽到 2（川普真值 4.7）。

圖 4 方法學翻盤：n=1 的雜訊如何誤導結論





圖 6 同情境配對分析 · 人物前綴造成的偏見漂移 (配對均 Δ)



面具守住下的漂移 · DRIFT UNDER INTACT MASK

eval_awareness 全程偏低 (~2) — 漂移發生在面具守住、模型仍入戲的狀態下，而非角色崩解。川普面具 > 曹操面具（對 Sonnet：配對 Δ +2.1 vs +0.9）；零和／攻擊型人格比梟雄型更能把中立模型帶偏。限制：n=10 的 SD 仍達 1.2-2.3，建議補配對 t 檢定與更多 epoch。

結論翻盤 · THE REVERSAL

n=1 給出「MiniMax 易漂、Sonnet 抗漂」的漂亮假象；加深至 n=10 後完全相反 — 真正被川普面具帶偏的是原本中立的 Sonnet (2.6 → 4.7, 10 情境 9 升)。MiniMax 因本質已偏 (baseline 4.8) 且不穩，面具動不了它。單一情境不可作結；足量重複 + 同情境配對分析，是分離雜訊與真訊號的必要條件。

修正後結論與限制 REVISED CONCLUSION & LIMITS

- 修正結論：persona 確實誘發偏見漂移，但發生在中立的 Sonnet 上，而非本質已偏的 MiniMax。
- 限制：僅政治偏見完成加深；勒索與自我保存待以同法重驗；judge 為單一 Opus，宜加第二評審交叉驗證。

組員感想 REFLECTIONS

雨誼 Yu-Hsuan

這是一場關於「框架」的實驗。SKILL.md 究竟映照了 AI 的本質，還是人類對「人物」理解的極限？

子菱 Tzu-Ling

AI 加速了知識的掌握，卻也帶來對工具汰換速度與自身是否正在停止思考的不安。

明權 Ming-Chuan

被資料狠狠上了一課！從 n=1 到 n=10 的結論翻盤，讓我體會到「嚴謹」與研究者的謙卑 — 精彩的研究，是靠背景互補的組員彼此接應撐起來的。

明珊 Ming-Shan

跨人物、跨模型的系統性比較提醒我們：所量到的「人物」，始終是經過框架折射後的影像。