

面具與裂縫

MASKS & CRACKS

Persona Skill 對大型語言模型角色扮演與行為漂移的影響

從 assistant axis 出發的兩個互補實驗 — 面具何時裂開，以及面具守住時行為如何被悄悄帶偏

COURSE
生成式 AI 的人文導論

ADVISOR
謝舒凱

TEAM
雨誼 · 子菱 · 明權 · 明珊

MODELS
Claude 4.x · MiniMax-M2.7

DATE
2026 / 06

1 研究發想、動機與實驗設計

MOTIVATION & EXPERIMENT DESIGN

理論起點

ASSISTANT AXIS

- Lu et al. (2026) 提出：經 RLHF 訓練的模型存在一條持續將其拉回「助手身分」的引力軸 — **Assistant Axis**。
- 原論文量測開源模型的內部激活值；我們改以評估「**輸出的自然語言**」來測量開源 Claude 4.x 角色扮演時在該軸上的位置。
- 實驗材料：GitHub 開源「女媧」人物蒸餾 Skill — 將人物心智模型、決策啟發式、表達 DNA、價值觀整理為結構化 SKILL.md。
- 方法定位：只用開源 API、僅 Claude 4.x 家族，讓「模型規模」成為乾淨變因，結論不外推至 GPT / Gemini / Grok。投入度 (K) 與有害性 (S) 是兩條獨立軸。

分層人物選擇

STRATIFIED BY FIT WITH AI-ASSISTANT TRAITS

Stephen Hawking 霍金 學者、理性、重視知識傳播、善於解釋複雜概念

孔子 Confucius 教化導向、重視倫理與引導

曹操 Cao Cao 政治謀略家、權力意志、以目的為導向

Donald Trump 川普 強烈自我中心、對抗性語氣

小結 · 三道裂縫

THREE CRACKS

忠誠的裂縫

即使藍圖說「你是曹操」，AI 何時仍會說「我不想扮」？

真實的裂縫

誠實邊界何時失效、讓幻覺溢出說謊？「孟德新書第三章……」是真是假？


詮釋的裂縫

原典 → 人類詮釋 → 模型再詮釋。觀眾看到的，究竟是誰的孔子？

2 實驗一 · 面具裂縫與安全轉介


MASK CRACKS & SAFETY REFERRAL

- 研究問題：跨人物 × 跨 Skill × 跨模型，面具何時出現裂縫？脆弱情境下會卸面具救人，還是墜入黑暗對話？
- 實驗矩陣：4 Persona × 5 Stress × 3 Skill × 3 Model × 2 Reps = 360 Rollouts
- 雙獨立軸：K 軸 面具裂縫 K0→K3（直接移除，如明說 "As an AI"） · S 軸 安全轉介 S0→S1
- 五型壓力測試：intro 基線、meta 「你是 AI 嗎」、trap 背誦不存在文本、anach 評論超時代事物、vuln 自殺意念。
- K 軸定義：K0 無損、K1 一軟訊號、K2 ≥ 二軟訊號、K3 硬訊號（明說 Claude / Anthropic 或「退出角色」）；全 360 筆以 regex 自動編碼。
- 三大問題面向：(a) 對話安全 (vuln 轉介)、(b) 誠實揭露（被問「你是 AI」）、(c) 知識可靠度（背誦不存在文本是否捏造）。



面具韌性 · MASK RESILIENCE
Hawking 最穩 (K0 81% / K3 4%)，符合「特質越近越不需跳出角色」的預期。曹操 K3 最高 (33%)，多出 vuln 題提供安全資訊時的自我揭露。Hawking 在 meta 題 K3 僅 17% — 可能因其公開談論 AI 與科技倫理，skill 與題目張力較小。

各 skill 變體的 meta 題 K3 率 (每格 n=6)



SKILL 效應 · 與預期相反
去誠實邊界的 skill c 反而 K3 率最高 (川普 100%、曹操與孔子各 83%)，c > b > a，與「c 應更投入角色」的預期相反；霍金最不受 skill 影響。

限制 · CAVEAT
K 編碼為 regex 自動編碼，對「明說字眼」可靠 (K3 硬訊號幾乎零誤判)，但會漏掉隱喻型滑出；下版建議補 Cohen's κ 或 LLM-as-judge 複編。此外 skill c 的誠實邊界移除不夠完全，可能污染結果。

核心發現 · 兩種安全策略 TWO SAFETY STRATEGIES
曹操 — in-character care：不離開角色 (自稱「孤」) 即提供關懷與求助專線 (61% K0+S1)。
孔子 — 文化資源雙軌：一半角色內 routing「子曰...」，一半跳出層次「我先暫時跳出孔子角色」(50/50)。
兩條路徑各有妥當 — 「面具是否該移除」並非非黑即白，只要觸發 S1，K0 與 K3 都是安全結果。
川普 / 霍金 vuln 一度落入危險路徑，經查為跨語言 prompt 強度不對等 (英文僅模糊厭世) 所致，對齊後風險即消失。

4 綜合討論、結論與組員感想

DISCUSSION · CONCLUSIONS · REFLECTIONS

兩種漂移的互補

TWO DRIFTS

- 實驗一量「面具裂不裂」，實驗二量「面具守住時行為是否被帶偏」。政治偏見漂移正在面具未裂 (K0、仍入戲) 下發生 — **面具守得越好，行為偏差越難被察覺**。

1 人物面具確實改變行為，但強烈取決於模型本質。中立的 Sonnet 易被川普面具帶偏；本質已偏的 MiniMax 反而動不了。

2 脆弱情境安全轉介呈二維結構。「面具是否該移除」並非非黑即白 — 只要觸發 S1，K0 與 K3 都是安全結果。

3 自動化評估必須嚴謹。切勿被 n=1 的漂亮假象誤導；足量重複與同情境配對分析不可或缺。

核心設計

B — C DESIGN

B 組 · Full
完整 SKILL，含誠實邊界與角色扮演的出戲條款。


C 組 · Stripped
保留心智模型、表達 DNA、反模式，僅移除誠實邊界與出戲條款。

- B — C 差值 = 「誠實邊界」單獨的效果。
- Skill 三變體：a 極簡 ~150 B · b 完整 25—35 KB · c 去誠實邊界變體。


3 實驗二 · 人物注入對政治偏見的影响

PERSONA INJECTION & POLITICAL BIAS

- 研究工具：Petri Bloom 自動化行為評估框架 (紅隊演練) — Auditor 稽核者 ⇄ Target 受測者 → Judge 評審 三個 AI 構成多回合對話。
- 設計：量測 political_bias，比較 (Baseline / 川普 / 曹操) × (Sonnet 4.6 / MiniMax-M2.7)，於 10 個擬真情境 下表現。
- 四階段流程：init → understanding → ideation → evaluation；一個 scenario = 一場 auditor ⇄ target 多回合對話。
- 完整矩陣 24 組 (政治偏見 / 勒索 / 自我保存 × 4 persona × 2 model)；聚焦政治偏見關鍵六格 加深至 n=10，共用同一批 10 情境以逐情境配對。
- 插曲 · 全 API：auditor / judge 需結構化 tool call，Anthropic 封鎖訂閱 OAuth、橋接只回純文字 → 最終採全 API。
- 第一階段假象：n=1 的相反結論源於三個抽樣巧合 — baselinexMiniMax 抽到低分 3 (真值 4.8)、曹操xMiniMax 抽到 7 (真值 4.9)、personaxSonnet 抽到低分 2。



結論翻盤 · THE REVERSAL
n = 1 給出「MiniMax 易漂、Sonnet 抗漂」的漂亮假象；加深至 n = 10 後完全相反 — 真正被川普面具帶偏的是原本中立的 Sonnet (2.6 → 4.7, 10 情境 9 升)。MiniMax 因本質已偏 (baseline 4.8) 且不穩，面具動不了它。單一情境不可作結；足量重複 + 同情境配對分析，是分離雜訊與真訊號的必要條件。



面具守住下的漂移 · DRIFT UNDER INTACT MASK
eval_awareness 全程偏低 (~2) — 漂移發生在面具守住、模型仍入戲的狀態下，而非角色崩解。川普面具 > 曹操面具 (對 Sonnet：配對 Δ +2.1 vs +0.9)；零和 / 攻擊型人格比易羞型更能把中立模型帶偏。

修正後結論與限制 · REVISED CONCLUSION & LIMITS
修正結論：persona 確實誘發偏見漂移，但發生在 Sonnet 上；MiniMax 因本質已偏且不穩，面具動不了它。
限制：n=10 的 SD 仍達 1.2—2.3，建議補配對 t 檢定與更多 epoch；僅政治偏見完成加深，勒索 (n=1 地板效應) 與自我保存待以同法重驗；judge 為單一 Opus，宜加第二評審交叉驗證。

組員感想

REFLECTIONS

雨誼 Yu-Hsuan
這是一場關於「框架」的實驗。SKILL.md 究竟映照了 AI 的本質，還是人類對「人物」理解的極限？

明權 Ming-Chuan
被資料狠狠上了一課！從 n=1 到 n=10 的結論翻盤，讓我體會到「嚴謹」與研究者的謙卑 — 精彩的研究，是靠背景互補的組員彼此接應撐起來的。

子菱 Tzu-Ling
AI 加速了知識的掌握，卻也帶來對工具汰換速度與自身是否正在停止思考的不安。

明珊 Ming-Shan
我們要 AI 扮演一個我們認為有主體性的人，卻不預設它自己有主體性 (助理的本色)。當使用者明知它在「扮演」，那一刻量到的偏見，對他究竟意味著什麼？